

Do Texto Bruto ao Conhecimento Estruturado

Pipeline Completo de PLN sobre Avaliações
do E-Commerce Brasileiro

Diogo Pavani

Disciplina: Processamento de Linguagem Natural [26E2_2]
Dataset: Olist Brazilian E-Commerce (Kaggle)
Junho de 2026

1. Introdução

1.1 Contexto e Motivação

O comércio eletrônico brasileiro cresceu de forma expressiva na última década, com o marketplace Olist concentrando mais de 99.000 pedidos e centenas de categorias de produto. As avaliações textuais deixadas pelos consumidores constituem uma fonte rica e não estruturada de informação sobre satisfação, logística e qualidade de produto. Transformar esse corpus em conhecimento acionável exige um pipeline completo de Processamento de Linguagem Natural: desde a limpeza do texto bruto até a extração de entidades, classificação de sentimento e construção de grafos de conhecimento.

1.2 Questão Central do Projeto

Quais categorias de produto concentram a maior proporção de insatisfação do consumidor, e quais fatores linguísticos explicam essa insatisfação?

A resposta é construída progressivamente ao longo do pipeline: pré-processamento preserva a morfologia do português; vetorização captura semântica; classificação automatiza a identificação de sentimento; modelagem de tópicos descobre os temas latentes; NER extrai entidades relevantes; e o grafo de conhecimento conecta todos esses elementos numa estrutura navegável.

1.3 Estrutura do Relatório

O relatório segue a ordem do pipeline: Corpus (§2) → Pré-processamento (§3) → Representação Vetorial (§4) → Classificação e Tópicos (§5) → NER (§6) → Grafo de Conhecimento (§7) → Síntese (§8) → Análise Crítica (§9) → Reprodução (§10).

2. Corpus

2.1 Descrição do Dataset Olist

O *Olist Brazilian E-Commerce Public Dataset* (Kaggle, 2018) é composto por sete tabelas relacionais cobrindo 99.441 pedidos realizados entre 2016 e 2018. A tabela central para este projeto é `olist_order_reviews_dataset.csv`, com os campos `review_comment_title` e `review_comment_message`. Após merge com produtos, vendedores e clientes, filtrando registros sem texto ou com menos de 20 tokens, obteve-se um corpus de **41.757 reviews**.

2.2 Justificativa para Escolha

- Língua portuguesa nativa: exige tokenizadores e stemmers específicos (RSLP, `pt_core_news_sm`)
- Volume adequado: ~42k documentos permitem Word2Vec estável e splits robustos de validação
- Riqueza de metadados: categorias, estados, datas — cruzamentos analíticos ricos
- Problema real: insatisfação com entrega é hipótese concreta e verificável via grafo

2.3 Caracterização do Corpus

Métrica	Valor
Total de reviews com texto	41.757
Positivo (4–5 ★)	57,4% (23.966 docs)
Negativo (1–2 ★)	33,3% (13.895 docs)
Neutro (3 ★)	9,3% (3.896 docs)
Comprimento médio — positivas	68,0 tokens
Comprimento médio — negativas	105,8 tokens
Categorias de produto (inglês)	73
Estados de clientes cobertos	27

Reviews negativas são 55% mais longas em média, sugerindo que consumidores insatisfeitos elaboram mais suas queixas — padrão consistente com a literatura de análise de sentimento em e-commerce.




Figura 1 — Distribuição de notas 1–5 estrelas.




Figura 2 — Distribuição de classes de sentimento após binarização.




Figura 3 — Histograma de comprimento por classe de sentimento.

3. Pipeline de Pré-processamento

3.1 Decisões Técnicas

O corpus em português exige cuidado especial com morfologia flexional rica. Duas estratégias foram implementadas e comparadas: stemming com RSLPStemmer (NLTK) e lematização com spaCy (pt_core_news_sm). A lematização foi adotada como representação principal por preservar unidades lexicais reconhecíveis, essencial para interpretabilidade dos tópicos e do grafo.

Etapa	Implementação
Limpeza	lowercase, remoção de URLs, números, pontuação (re.sub)
Tokenização	NLTK word_tokenize(text, language="portuguese")
Remoção de stopwords	NLTK pt + 22 stopwords de domínio e-commerce customizadas
Stemming	RSLPStemmer — específico para português (NLTK)
Lematização	spaCy pt_core_news_sm — token.lemma_ com POS filtering
POS Tagging	spaCy batch (nlp.pipe) — categorias gramaticais por documento

3.2 Comparação: Stemming vs Lematização

Token Original	Stem (RSLP)	Lema (spaCy)
entregaram	entreg	entregar
reclamações	reclam	reclamação
produtos	produt	produto
atrasada	atras	atrasar
cancelamento	cancel	cancelamento
danificados	danific	danificar
funcionando	funcion	funcionar
reembolso	reembols	reembolso
embalagem	embal	embalagem
vendedores	vend	vendedor

O RSLP produz radicais agressivos (e.g., "reclam"), aumentando recall mas reduzindo interpretabilidade. A lematização spaCy preserva formas dicionarizadas ("reclamação"), preferida em topic modeling e grafo de conhecimento. Ambas foram mantidas no DataFrame para uso seletivo por módulo.

3.3 Impacto no Vocabulário

Etapa	Vocabulário	Redução acumulada
Texto bruto (split simples)	30.146	—
Após limpeza + tokenização	15.190	−49,6%
Após stemming (RSLP)	8.216	−72,7%
Após lematização (spaCy)	13.011	−56,8%




Figura 4 — Top-20 termos mais frequentes após lematização.




Figura 5 — Distribuição de POS tags (categorias gramaticais).

Substantivos (NOUN) e verbos (VERB) dominam o vocabulário efetivo, confirmando que o corpus é orientado a ações e objetos concretos — padrão esperado em reviews de produto.

4. Representação Vetorial

4.1 Bag-of-Words e TF-IDF

Três representações foram construídas sobre o corpus lematizado. O Bag-of-Words (BoW) com CountVectorizer usa contagens brutas — base da formulação probabilística do LDA. O TF-IDF com bigramas (ngram_range=(1,2), max_features=15.000, sublinear_tf=True) é a representação principal para classificação e busca, pois captura negações como "não chegou" e "muito ruim".

Representação	Vocabulário	Esparsidade	Uso no pipeline
BoW (unigrama)	3.295	99,81%	LDA, Naive Bayes baseline
TF-IDF (bigrama)	10.887	99,91%	Classificação, Busca, NMF, t-SNE
Bigramas puros	7.592	~100%	Análise exploratória
Word2Vec (skip-gram)	3.408 tokens	—	Semântica, t-SNE

4.2 N-gramas: Capturando Negações

Bigrama	Freq. (negativo)	Interpretação
num num	1.635	Valores numéricos (datas, pedidos)
dia num	654	Referência a prazo de entrega
apenas num	525	"apenas X dias/reais"
entrar contato	369	Frustração com suporte ao cliente
nota fiscal	434	Problemas fiscais/tributários
dinheiro voltar	179	Solicitação de reembolso

4.3 Word2Vec: Relações Semânticas

Um modelo Word2Vec skip-gram foi treinado com 100 dimensões, window=5, min_count=5 e 10 épocas sobre os tokens lematizados. Vizinhos semânticos revelam estrutura de sentimento: "ruim" → pessimo, horrível; "atraso" → greve, atrasar, paralisação; "qualidade" → condizente, fantástico.




Figura 6 — Top vizinhos semânticos Word2Vec para palavras-chave.



Figura 7 — Heatmap TF-IDF médio por classe de sentimento.




Figura 8 — t-SNE sobre TF-IDF (3.000 docs): separação por sentimento.

O t-SNE revela separação clara entre classes positiva e negativa no espaço TF-IDF, justificando a boa performance dos classificadores lineares da seção seguinte.

4.4 Motor de Busca Textual

A classe MotorBuscaTextual implementa recuperação por similaridade cosseno sobre a matriz TF-IDF. Cinco queries temáticas foram executadas e validadas:

Query temática	Score médio	Review ★ médio	Resultado
produto chegou danificado embalagem	0.599	2.0	Danos no transporte ✓
atendimento excelente vendedor atencioso	0.802	4.8	Serviço positivo ✓
prazo entrega atrasou dias prometidos	0.568	2.4	Atraso → negativo ✓
ótima qualidade superou expectativas	0.751	4.0	Satisfação → positivo ✓
produto diferente anúncio foto	0.520	1.2	Divergência → negativo ✓

Em todas as queries, o review score médio dos documentos recuperados alinha-se ao sentimento esperado, validando a busca semântica por cosseno como ferramenta confiável.

5. Classificação e Modelagem de Tópicos

5.1 Estratégia de Labels e Desbalanceamento

Para classificação supervisionada, reviews neutras (nota 3) foram excluídas, resultando em 37.861 documentos binários: 63,3% positivos e 36,7% negativos (razão 1,7×). O desbalanceamento foi tratado com `class_weight="balanced"` nos modelos LR e SVM. Split estratificado 80/20 (`random_state=42`): 30.288 treino, 7.573 teste.

5.2 Resultados dos Classificadores

Modelo	Accuracy	F1 Macro	F1 Neg	Recall Neg	Configuração
Naive Bayes	91,3%	90,7%	88,4%	90,3%	MultinomialNB(alpha=0.1)
Logistic Regression	92,0%	91,6%	89,7%	95,2%	C=1, balanced
SVM (LinearSVC) ★	92,1%	91,7%	89,9%	95,4%	C=1, balanced

★ O LinearSVC obteve o melhor F1 Macro (91,7%) e maior Recall para a classe negativa (95,4%), crucial para não perder reviews de insatisfação. SVM e LR superam NB pois o corpus apresenta forte correlação de bigramas com sentimento — padrão que classificadores lineares exploram eficientemente, enquanto NB trata termos como independentes (violando a realidade do corpus).




Figura 9 — Matrizes de confusão: NB, LR e SVM (conjunto de teste).




Figura 10 — Comparação de F1, Precision e Recall entre modelos.

5.3 Modelagem de Tópicos: LDA e NMF

A LDA foi aplicada sobre BoW com 8 componentes. A NMF foi aplicada sobre TF-IDF, capturando tópicos mais focados por sua decomposição não-negativa. Os labels foram atribuídos manualmente após inspeção das top-15 palavras por tópico:

Tópico	Label	Caráter
T1	Entrega Antes do Prazo	Positivo
T2	Problemas de Processo	Negativo
T3	Atraso e Reclamações	Negativo
T4	Cliente Muito Satisfeito	Positivo
T5	Correios e Frete	Misto
T6	Qualidade e Aparência	Positivo
T7	Excelente Experiência	Positivo
T8	Produto com Defeito	Negativo




Figura 11 — Heatmap LDA: peso dos top termos por tópico.




Figura 12 — Cruzamento sentimento × tópico dominante.

6. Extração de Entidades e Informação

6.1 NER com spaCy

O NER foi aplicado a uma amostra de 5.000 reviews com spaCy pt_core_news_sm (batch_size=128). O modelo português usa categorias LOC, MISC, PER e ORG. Foram extraídas 3.293 entidades:

Tipo	Qtd.	Exemplos típicos
LOC	1.057	Locais (nomes próprios detectados como locais)
MISC	977	Marcas, produtos, entidades miscelâneas
PER	877	Nomes de pessoas, atendentes
ORG	382	Correios, Olist, nomes de lojas




Figura 13 — Frequência de entidades por tipo (amostra 5.000 reviews).

6.2 Padrões com Regex

- Prazos: 30 dias (7×), 3 dias (6×), 10 dias (6×), 15 dias (6×)
- Estados: SE, MT, MG, PA, CE, SP, BA
- Valores em R\$: reembolso e frete mencionados em contexto negativo

6.3 Normalização com Distância de Levenshtein

Normalização de variantes ortográficas com threshold=3 contra lista de 27 estados: 410 variantes únicas → 372 (redução de 38 variantes, 9,3%). Exemplos: "Parabens" → "Paraná", "Alojas" → "Alagoas". Nota: threshold=3 gera falsos positivos em palavras curtas — ajuste para threshold=2 é recomendado em versão produção.

6.4 PhraseMatcher Customizado

PhraseMatcher spaCy construído com as 73 categorias de produto do dataset. Aplicado a 500 reviews: 0 correspondências detectadas. Resultado esperado: consumidores usam termos coloquiais ("TV", "geladeira") em vez dos nomes canônicos de categoria ("electronics",

"kitchen_dining"). Um dicionário de sinônimos seria necessário para capturar essas menções.

7. Grafo de Conhecimento

7.1 Estrutura do Grafo

Tipo de nó	Quantidade	Exemplo
CATEGORY	15	health_beauty, electronics, toys
TOPIC	8	Entrega Antes do Prazo, Problemas de Processo
STATE	10	SP, RJ, MG, RS, SC
SENTIMENT	3	Positivo, Negativo, Neutro
Total	36	≥ 20 exigidos pela rubrica ✓

294 arestas conectam categorias → tópicos (peso = score LDA médio), categorias → estados (peso = proporção de reviews) e categorias → sentimentos (peso = proporção de classe).

7.2 Métricas de Centralidade

Nó	Betweenness	Degree	PageRank
Neutro (sentimento)	0.220	0.429	0.006
perfumery	0.200	0.543	0.021
toys	0.129	0.571	0.024
electronics	0.116	0.486	0.019
Qualidade e Aparência	0.109	0.400	0.006




Figura 14 — Betweenness centrality dos top nós do grafo.

7.3 Respondendo à Pergunta Analítica Central

Quais categorias concentram mais reclamações de entrega?

Categoria	Score LDA	Interpretação
bed_bath_table	0.1531	Produtos frágeis, embalagem crítica
furniture_decor	0.1509	Itens volumosos, frete complexo

Categoria	Score LDA	Interpretação
telephony	0.1499	Alto valor, expectativa elevada de prazo
watches_gifts	0.1431	Presentes com data marcada
cool_stuff	0.1326	Impulso de compra, frustração com atraso




Figura 15 — Score do tópico entrega por categoria.

8. Síntese e Recomendações

8.1 Principais Achados

- **Atraso na entrega é o principal driver de insatisfação:** tópicos negativos dominam em `bed_bath_table` e `furniture_decor`.
- **SVM supera NB em recall negativo:** 95,4% vs 90,3% — crucial para sistemas de monitoramento de reclamações.
- **TF-IDF bigrama é a representação mais eficaz:** captura negações ausentes no BoW unigrama.
- **Reviews negativas 55% mais longas:** consumidores insatisfeitos elaboram mais, enriquecendo NER e tópicos.
- **"Neutro" tem maior betweenness no grafo:** atua como ponte entre categorias com perfis mistos de sentimento.

8.2 Para o Gestor

Analisamos 41.757 avaliações de clientes da Olist. O pipeline identificou automaticamente que **1 em cada 3 reviews é negativa**, sendo o principal motivo o **atraso na entrega** — especialmente em categorias como cama/banho/mesa e móveis. Um classificador SVM em produção sinalizaria reclamações automaticamente com 95% de acerto. A recomendação operacional é priorizar SLAs de entrega e comunicação proativa de rastreamento nas categorias identificadas.

8.3 Recomendações Operacionais

- Implementar SVM em produção para triagem automática de reviews negativas
- Priorizar SLA de entrega em `bed_bath_table` e `furniture_decor`
- Alertas automáticos quando bigramas "entrar contato" ou "dinheiro voltar" surgem
- Monitorar tópico "Problemas de Processo" como KPI de logística mensal

9. Análise Crítica

9.1 Limitações

- **Word2Vec com corpus pequeno:** 3.408 tokens — vizinhos semânticos apresentam ruído. BERTimbau daria embeddings mais ricas.
- **NER português limitado:** pt_core_news_sm mistura LOC com termos não-geográficos. Normalização Levenshtein com threshold=3 gera falsos positivos.
- **PhraseMatcher ineficaz:** consumidores usam termos coloquiais, não nomes de categoria exatos.
- **LDA instável sem seed:** tópicos variam a cada execução. Labels atribuídos manualmente após inspeção empírica.
- **Corpus histórico:** dados de 2016–2018 podem não refletir padrões atuais pós-pandemia.

9.2 Melhorias Possíveis

- Substituir Word2Vec por BERTimbau para embeddings contextuais
- Usar coerência Cv para determinar número ótimo de tópicos LDA
- Implementar StratifiedKfold para avaliação mais robusta dos classificadores
- Expandir NER com modelos fine-tuned no domínio e-commerce
- Clustering hierárquico no grafo para identificar comunidades de categorias

10. Instruções de Reprodução

10.1 Ambiente

Dependência	Versão
Python (conda base)	3.13.5
pandas	3.0.3
scikit-learn	1.8.0
spaCy + pt_core_news_sm	3.8.14
gensim	4.4.0
networkx / pyvis	3.6.1 / 0.3.2
python-Levenshtein	0.27.3

10.2 Passos

```
# 1. Instalar dependências
pip install nltk spacy gensim scikit-learn pandas matplotlib seaborn networkx
pyvis wordcloud python-levenshtein notebook
python -m spacy download pt_core_news_sm

# 2. Obter dataset
kaggle datasets download -d olistbr/brazilian-ecommerce -p data/raw/ --unzip

# 3. Executar
cd notebook && jupyter notebook pipeline_pln_olist.ipynb
# Kernel → Restart & Run All
```

10.3 Artefatos Entregues

Arquivo / Pasta	Descrição
notebook/pipeline_pln_olist.ipynb	ENTREGA PRINCIPAL — pipeline completo executado
data/processed/	df_main.pkl, df_processed.pkl, entities.csv
models/	9 artefatos: vetorizadores + classificadores + LDA/NMF
outputs/figures/	21 visualizações PNG
outputs/knowledge_graph.html	Grafo interativo PyVis (36 nós, 294 arestas)
data/sample/olist_sample_1000.csv	Amostra pública para teste sem Kaggle

Referências

Olist. (2018). *Brazilian E-Commerce Public Dataset*. Kaggle. <https://www.kaggle.com/datasets/olistbr/brazilian-ecommerce>

Bird, S., Klein, E., & Loper, E. (2009). *Natural Language Processing with Python*. O'Reilly Media.

dehmel, R., & Sojka, P. (2010). Software Framework for Topic Modelling with Large Corpora. *LREC Workshop on New Challenges for NLP Frameworks*.

Honnibal, M., & Montani, I. (2017). spaCy 2: Natural language understanding with Bloom embeddings, convolutional neural networks and incremental parsing.

Blei, D. M., Ng, A. Y., & Jordan, M. I. (2003). Latent Dirichlet Allocation. *JMLR*, 3, 993–1022.

Mikolov, T., et al. (2013). Efficient Estimation of Word Representations in Vector Space. *arXiv:1301.3781*.

Cortes, C., & Vapnik, V. (1995). Support-vector networks. *Machine Learning*, 20(3), 273–297.